

INGENIERÍA DE SERVIDORES (2016-2017)
GRADO EN INGENIERÍA INFORMÁTICA
UNIVERSIDAD DE GRANADA

IBM mainframes Machine Learning & Watson

Francisco Javier Morales Piqueras
Rubén Morales Pérez

28 de mayo de 2017

Índice

1	Resumen	3
2	Memoria	3
2.1	Introducción	3
2.2	IBM mainframes	3
2.2.1	Arquitectura	4
2.2.2	Hardware	5
2.3	Watson	6
2.3.1	Arquitectura	7
2.3.2	Entendiendo las preguntas	7
2.3.3	Evolución del sistema	9
2.4	IBM Bluemix	10
2.4.1	Agente conversacional	10
2.4.2	Detección de emociones en texto escrito	10
3	Conclusiones	11

Índice de figuras

2.2.	Computación grid, imagen	4
2.3.	Tipos de trabajo en un mainframe [?]	5
2.4.	Watson en Jeopardy!	6
2.5.	Arquitectura DeepQA	7
2.6.	Evolución del sistema Watson [?]	9
2.7.	Logo IBM Bluemix [?]	10

Índice de tablas

1. Resumen

2. Memoria

2.1. Introducción

Hay varios retos que tienen las compañías actualmente para poder mantenerse competitivas en un mundo cada vez más globalizado. El mundo de las tecnologías de la información y la comunicación toma un papel fundamental, cada vez hay más corporaciones con página web, aplicaciones u ofreciendo información actualizada a través de redes sociales.

Una vez que tenemos una base tecnológica y cierto volumen de negocio es recomendable pasar al siguiente nivel, tener datos suficientes y de calidad recopilados de forma que podamos obtener un beneficio competitivo extrayendo información. Entonces entra en juego el análisis de datos y mantener esa información segura, por temas de protección de datos. Aquí es donde interviene IBM mainframes [?], grandes ordenadores que nos ofrecen computación en la nube de forma que podremos almacenar los datos en dichos servidores con cierta garantía y a la vez dejar a estos ordenadores el procesamiento pesado.

El primer ordenador digital de propósito general de IBM fue ASCC (Automatic Sequence Controlled Calculator), se desarrolló junto con la Universidad de Harvard. Entre los sistemas más modernos hablaremos de z Systems.



(a) ASCC



(b) Z13

2.2. IBM mainframes

Usaremos la siguiente definición de mainframe [?]

”Un mainframe es lo que las empresas usan para alojar bases de datos comerciales, servidores de transacciones y aplicaciones que requieren un mayor grado de seguridad y disponibilidad de lo que comúnmente se encuentra en máquinas de menor escala”

El desarrollo de este tipo de computadoras comenzó en los años cincuenta, las grandes empresas los utilizaban como repositorios de datos. El término evolucionó desde considerarse puramente el hardware de IBM hasta entenderse como un estilo de computación en sí mismo. Un punto de inflexión en la historia de los mainframes fue el *S/360*. En los sesenta se comenzó a estandarizar tanto el hardware como el software.

El *S/360* fue el primero de estos ordenadores en usar microcódigo para muchas instrucciones máquina, sin tener todas sus instrucciones cableadas. El microcódigo (o firmware) consiste en microinstrucciones (no disponibles para los usuarios) que proporcionan una capa funcional entre el hardware y el software, nos ofrece flexibilidad ante cambios sin tener que reemplazar el hardware. Las primeras aplicaciones empresariales se escribieron en ensamblador, COBOL, FORTRAN o PL/1, y muchos de estos programas todavía están en uso hoy en día.

2.2.1. Arquitectura

A principios de los noventa el modelo cliente/servidor (con nodos menos potentes distribuidos) emergió para desafiar el dominio de los mainframe, por aquel entonces llamados dinosaurios. Los diseñadores crearon nuevos mainframe llamados T-Rex, algunos de los servicios que ofrecían eran el servicio web, mayor autonomía, recuperación ante desastres y computación grid. La computación grid hace referencia al uso simultáneo de diferentes recursos hardware y software cumpliendo varias características [?]:

- Coordinar recursos de forma descentralizada
- Protocolos e interfaces estándares, abiertos y de propósito general
- Ofrecer un servicio no trivial




Figura 2.2: Computación grid, imagen

Hoy en día se utiliza más el término servidor, cuando tenemos un grupo lo llamamos granja y mainframe hace referencia a los servidores más grandes. Un mainframe a menudo implica una centralización de la computación, aunque una empresa grande puede distribuir sus servicios en varios servidores. Los mainframes tienen la capacidad de configurarse dinámicamente, añadir procesadores, memoria y conexiones, mientras las aplicaciones continúan ejecutándose. Cuando usamos un mainframe tenemos mayor flexibilidad y evitamos actualizar varios computadores a la vez, sin embargo, tener varios computadores distribuidos aumenta la potencia de cálculo en relación al precio.

A menudo se utiliza el término plataforma para referirse al hardware y software como conjunto. El mainframe en sí suele cumplir varias de las siguientes características [?]:

- Compartir acceso disco con otros sistemas, con protección de los datos y control de privilegios.
- Procedimientos sistemáticos de copias de seguridad y recuperación desde otra ubicación.
- Trabajo rutinario con operaciones simultáneas de E/S.
- Permitir usar varias copias del sistema operativo como un único sistema, dicha tecnología se conoce como Parallel Sysplex (cluster en UNIX).
- Gran capacidad de compartir datos y recursos.

Las fortalezas se representan mediante las siglas RAS (Reliability, Availability y Serviceability)

- Confiabilidad: El hardware tiene comprobación y recuperación de errores y se aplican actualizaciones software cuando existe un problema

- Disponibilidad: Capacidad de reemplazamiento del hardware y el software, aunque es deseable mantener un MTBF (Mean time between failure) lo más alto posible
- Utilidad: Entender el tipo de los errores, lo que permite conocer lo que hay que modificar

Para mantener una buena tolerancia a fallos debe incluirse un mantenimiento constante con copias de seguridad redundantes y controlar los accesos mediante privilegios, la seguridad de los datos se define como la protección contra el acceso no autorizado, la transferencia, la modificación o la destrucción, ya sea accidental o intencional. Otra cualidad deseable es la escalabilidad, capacidad de mantener niveles de rendimiento al agregar procesadores, memoria y almacenamiento.

Un mainframe suele realizar dos tipos de trabajo, procesamiento en segundo plano (scripts) o transacciones online, diferenciándose en la interacción con el usuario final.

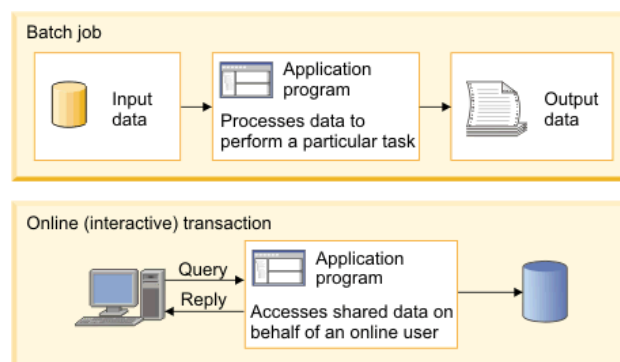


Figura 2.3: Tipos de trabajo en un mainframe [?]

2.2.2. Hardware

Además del grupo de procesadores primarios, los mainframes tienen una red de microprocesadores especiales que controlan el sistema. IBM utiliza el término CPC (Central Processor Complex) para referirse a la colección física de hardware que incluye almacenamiento principal, uno o más procesadores centrales, temporizadores y canales. A parte del procesador central un mainframe tiene un asistente SAP (System Assistance Processor) para las operaciones de entrada y salida. Las unidades de disco físicas son unidades de tipo SCSI aunque se puede utilizar SSA, para un acceso más rápido a los discos, suele usar un RAID 5.

El mainframe se divide en diversas partes lógicas, cada una puede soportar un sistema operativo. Se pueden distribuir los recursos entre las partes lógicas o usar el algoritmo interno de distribución de carga. El software que se necesita para un mainframe suele ser muy caro, de hecho a veces un cliente quiere el último mainframe y más lento, para reducir costes software (el software suele ir en función de la potencia). De hecho los mainframes tienen varios procesadores que no conmutan para la potencia en las licencias software, por ejemplo: Integrated Facility for Linux (IFL), zAAP, zIIP, Integrated Coupling Facility (ICF), también tienen procesadores de repuesto, llamados Spare. De hecho se llega a controlar la potencia de los procesadores principales insertando ciclos nulos en la secuencia de instrucciones del procesador. Cada procesador tiene 8KB compartidos para PSA (Prefix Storage Area) y se utiliza para el manejo de interrupciones y de errores.

La más sofisticada de las técnicas de clustering es Parallel Sysplex, permitiendo enlazar hasta 32 servidores con escalabilidad casi lineal. Hay otras técnicas de clustering, entre ellas Basic shared direct access storage devices (DASD) y Channel-to-channel (CTC) rings.

2.3. Watson

En 2007 IBM Research se propuso el reto de crear un sistema para competir con los grandes campeones en el juego Jeopardy!. Este sistema, en adelante Watson, entraría dentro de la categoría QA (Question answering), que engloba varias áreas de la ciencia de la computación y la inteligencia artificial. Algunas de estas áreas serían búsqueda y recuperación de información (IR), procesamiento de lenguaje natural (NLP), representación del conocimiento y razonamiento o el machine learning.



Figura 2.4: Watson en Jeopardy!

La comunicación humana es imperfecta, el lenguaje permite ambigüedades, polisemia, la misma información puede expresarse de varias formas, también tenemos ironías y la interpretación de una frase puede depender de conversaciones anteriores entre los interlocutores. Además, dicha comunicación no está estructurada (como en un lenguaje de programación o una base de datos), los datos no siempre están bien definidos y hay información implícita. A día de hoy la información no estructurada crece más rápido que la estructurada, por ello es buena idea desarrollar el análisis del lenguaje natural y hacer inferencia a partir de los datos de los que disponemos.

Desde 2001 hasta 2006 se construyó la base para el reconocimiento de información no estructurada, UIMA (Unstructured Information Management Architecture). UIMA proporciona una plataforma para integrar la información obtenida tras analizar textos, imágenes, etc. Su objetivo es integrar varios programas llamados *anotadores*, que asignan significado semántico a ciertas partes del texto o imagen.

Algunos desarrolladores habían participado anteriormente en Question answering dentro del proyecto PIQUANT [?]. Este sistema tenía un conjunto estático de tipos de respuestas (o clases de conceptos) que se solicitaban en una pregunta. El nuevo sistema no tendría conexión a Internet, y tendría que procesar la pregunta, buscar respuesta y estimar la probabilidad de que sea correcta. Tras analizar 2,000 partidas de *Jeopardy!* la media de los jugadores que ganaban era una precisión del 85 – 95 % de acierto sobre una media de 40 – 50 % de preguntas respondidas, o 85 % *Precision@40*. En 2007 se consiguió, usando PIQUANT, un rendimiento 16 % *Precision@70* en las preguntas de *Jeopardy!*.

- El generador PAS crea una representación abstracta, la interfaz con la parte analítica.

Para las **respuestas y fuentes de evidencia** se añadieron enciclopedias y libros de referencia. Después se desarrolló un proceso semiautomático para aumentar la base de conocimiento, añadir contenido sin parar afecta negativamente al rendimiento del sistema. Para extraer conocimiento de las fuentes seleccionadas se usa *PRISMATIC* [?].

Cada una de las consultas usa simultáneamente información estructurada y no estructurada . Una métrica que se usa para medir la bondad de una respuesta es el porcentaje de preguntas en las que dicha respuesta es generada como candidata. Esta medida ayuda sobre todo cuando tenemos varias interpretaciones diferentes de la pregunta. De las experiencias con *PIQUANT* se sabía que no era una estrategia adecuada intentar anticipar todos los tipos de respuesta y crear algoritmos que busquen solamente instancias de dichas clases. Todo el sistema se apoyaría en reconocer correctamente el tipo de respuesta y que la respuesta esté bien clasificada dentro del sistema. En la siguiente pregunta de la categoría *decoración* el tipo de respuesta buscada es una *dirección*:

Si usted está de pie, es la dirección que debe buscar para ver el revestimiento.

Respuesta: Abajo

Para clasificar las respuestas se usó un sistema dinámico que tenía en cuenta el contexto de la pregunta, su nombre es *coacción de tipo*. Otras técnicas usadas por Watson eran *YAGO* y *WordNet*. Otra fase del proceso es **recolectar y evaluar la evidencia** (de forma paralela) de las respuestas. Aquí se utiliza la deducción de relaciones semánticas a partir de datos de entrenamiento. Por ejemplo, esta pregunta de la categoría *Madres e hijos*:

Aunque solo les separa un año de vida, ella interpretó a la madre de Colin Farrell en Alexander.

Respuesta: Angelina Jolie

Relación: protagoniza(ella, Alexander)

En Jeopardy! hay preguntas que tienen referencias implícitas en la frase, y unas partes del enunciado pueden depender de otras, como en el siguiente ejemplo de la categoría *Antes y después*:

La estrella de Jerry Maguire que mantiene automáticamente la velocidad de tu vehículo.

Respuesta: Control Tom Cruise

Primero se detectan este tipo de preguntas y las referencias enlazadas. Para interpretar las preguntas se dividen en distintas partes lógicas que puedan ser exploradas independientemente y combinar los resultados. Por ejemplo, en esta pregunta con categoría *Animales ficticios*, el sistema puede buscar por un lado personajes introducidos en 1894 y por otro aquello relacionado con "Hindi for bear":

El nombre de este personaje, introducido en 1894, proviene de "Hindi for bear".

Respuesta: Baloo

El sistema debe mejorar las 2 horas de procesamiento que necesita para responder una pregunta (en 2008). El *UIMA-AS* permite a cualquier aplicación *UIMA* ser desplegada en procesos asíncronos que utilizan paso de mensajes. Cada pregunta genera varias preguntas candidatas que se ejecutan independientemente, cada respuesta potencial por pregunta se busca independientemente, y cada comprobación de evidencia también. Tras usar 2880 procesadores la latencia de respuesta bajó de dos horas a tres segundos.

Este sistema de pregunta-respuesta es estático y no aprovecha todo el potencial de la arquitectura DeepQA. Watson puede aplicarse a la salud modificando su base de conocimiento y enseñándole a hacer las preguntas adecuadas a los pacientes para obtener información sobre ellos e inferir una solución a partir de su historial médico.

2.3.3. Evolución del sistema

Watson en la actualidad no solamente se utiliza aplicado a la medicina, también se usa en finanzas e inteligencia de negocio en general.

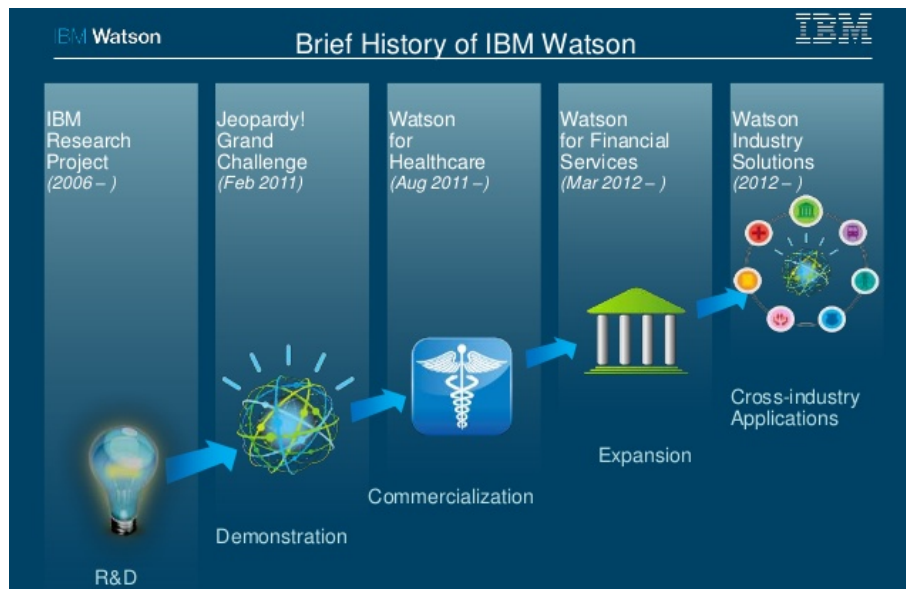


Figura 2.6: Evolución del sistema Watson [?]

2.4. IBM Bluemix

IBM Bluemix [?] es una plataforma de cloud computing que combina la plataforma como servicio (PaaS) con la infraestructura como servicio (IaaS).

Bluemix integra servicios que hacen uso de Watson como reconocimiento de lenguaje natural, traducción, reconocimiento de lenguaje por voz, conversión de formatos de archivo, reconocimiento de emociones en texto escrito, reconocimiento de imágenes o agentes conversacionales. Permite además, adaptar estos servicios a múltiples contextos. Por ejemplo, si queremos un agente conversacional para controlar determinadas funciones de un coche, podemos desarrollar uno gracias a Watson que domine específicamente el léxico de los componentes de un coche. O, en el caso del reconocimiento de emociones en texto escrito, podemos programar un bot que analice las reacciones en Twitter a un producto que acaba de lanzar nuestra compañía, pero también podemos usarlo para medir la satisfacción de nuestros clientes cuando usan el servicio técnico.

Bluemix permite usar demos gratuitas de estos servicios, y para este trabajo hemos probado algunas de ellas.



Figura 2.7: Logo IBM Bluemix [?]

2.4.1. Agente conversacional

Nada más abrir el panel de configuración de nuestro agente conversacional nos ofrece la posibilidad de añadir *intents*. Los *intents* son distintos contextos de nuestra conversación. Un *intent* podría ser, por ejemplo `#turn_off`. Al contexto `#turn_off` pertenecerían todas aquellas frases en las que el usuario implica que quiere apagar algo, aunque no aparezcan literalmente las palabras “turn off” (por ejemplo, “stop the music” pertenecería a este *textintent*). Los *intents* son establecidos por el programador, y para cada uno de ellos debe introducir varios ejemplos de frases del usuario de ese tipo. Con el tiempo, Watson debería ser capaz de ampliar esa muestra y clasificar adecuadamente frases que no habían sido contempladas originalmente. Este comportamiento es similar al que usó Watson en *textitJeopardy!* para deducir qué se pedía con una frase aunque no se dijera explícitamente.

Para el servicio de agente conversacional hemos usado una demo de un agente pensado para usar como un asistente en el coche. Cuando decimos al agente “I’m hungry” este lo clasifica en el *intent* `#locate_amenity` (“localizar servicio”) y detecta el concepto “@amenity:restaurant” (de nuevo, hace un uso de los conceptos similar al usado en *textitJeopardy!*).

2.4.2. Detección de emociones en texto escrito

Otro de los servicios que ofrece Bluemix gracias a Watson es un servicio capaz de detectar emociones y tonalidad en un texto escrito. A continuación se muestran los resultados con algunas frases que

hemos introducido a modo de prueba. Hemos comprobado que el análisis de las emociones que hace se basa puramente en el léxico y no tiene en cuenta demasiado la semántica. Por ejemplo, en la frase “I hope he dies” solo detectaba tristeza, probablemente por el uso de la palabra “dies”, a pesar de que la frase claramente no expresa tristeza.

Como se ha mencionado previamente, uno de los posibles usos de este servicio es monitorizar las emociones de los clientes que hacen uso del servicio para que les sea lo más satisfactorio posible. En las siguientes figuras se muestra un ejemplo de este uso.

3. Conclusiones

Desde el siglo pasado, el reconocimiento del lenguaje natural ha vivido un progreso constante. Sin embargo, la victoria en 2011 de Watson en *Jeopardy!* marcó un antes y un después. El nivel de sofisticación actual permite ir más allá del simple reconocimiento de patrones: ahora podemos reconocer intenciones implícitas en una conversación, discernir entre los posibles significados de una expresión según el contexto de la conversación. Esto, unido a los grandes volúmenes de información disponibles en internet sobre cualquier tema y las mayores prestaciones de los servidores actuales abre un abanico de posibilidades que hace poco eran completamente inviables.

Empresas como IBM han sabido ver un creciente nicho de mercado en este terreno, ofreciendo servicios como traducción, reconocimiento de emociones en el texto escrito o agentes conversacionales. Lograr que un ordenador pueda mantener una conversación natural y coherente con un humano o la capacidad de reconocer el tono o la intencionalidad de las palabras es un logro que va, lógicamente, más allá de la simple satisfacción de nuestra curiosidad intelectual: el uso de estas tecnologías puede reportar beneficios para usuarios, empresas y a la sociedad en general. Los usuarios podrán tener experiencias más satisfactorias cuando contacten con el servicio técnico de un producto, controlar su casa o su coche con su voz usando expresiones naturales o hacer traducciones de calidad superior a las actuales. Las empresas podrán evaluar mejor la experiencia de sus clientes o analizar de manera más precisa las impresiones que causan sus productos. La sociedad podrá beneficiarse, por ejemplo, de mejores sistemas de salud porque seremos capaces de diseñar médicos de cabecera artificiales que analicen mejor lo que le ocurre a los pacientes, tengan acceso a cantidades ingentes de información en un instante y puedan atenderlos en sus propias casas.

No obstante, sigue habiendo mucho margen de mejora en el reconocimiento del lenguaje natural. Durante la prueba del servicio de reconocimiento de emociones observamos que esta tecnología deja aún mucho que desear. A menudo las interpretaciones que hacía del texto se dejaban influir por el léxico sin tener en cuenta la semántica de la frase. En el futuro se debe mejorar este aspecto, así como lograr detectar ironías o dobles sentidos.

Otros retos tienen relación más directa con la ingeniería de servidores. Si queremos que los agentes conversacionales se parezcan lo suficiente a conversar con un humano, debemos mejorar los tiempos de latencia para que las respuestas sean instantáneas. Debemos ser capaces, también, de gestionar volúmenes cada vez mayores de información en cada vez menos tiempo.